

NILM Signal Disaggregation

Approcci sviluppati, benchmark

Executive summary

- Il progetto affronta il task NILM: stimare i contributi dei singoli elettrodomestici a partire dal solo segnale aggregato w_{medio} e da un inventario survey per IMEI.
- Sono stati sviluppati e testati approcci event-based, HMM, FHMM, template matching e una famiglia Gurobi con formulazioni binarie e multi-livello.
- Sul benchmark con copertura completa di 6 abitazioni idonee, $fhmm_1_dc$ e' il miglior modello medio con MAE di ricostruzione pari a 27.64 W.
- $gurobi_daywise$ e' competitivo come piattaforma di sviluppo: MAE medio 77.02 W, piu' interpretabile nei vincoli e piu' estendibile verso regole operative esplicite.
- Le estensioni survey-aware e multi-livello sono gia' implementate; il passo successivo consigliato e' una campagna benchmark sistematica su tutte le 6 abitazioni.

Obiettivo di business e perimetro

- Obiettivo: trasformare una misura energetica aggregata per abitazione in una stima per dispositivo, senza sensori invasivi e senza labels temporali di ground truth.
- Vincoli reali: segnale rumoroso, dispositivi simultanei, carichi sempre accesi, profili d'uso eterogenei e questionari incompleti.
- Dataset operativo: 6 abitazioni idonee con storico sufficiente e inventario dispositivi associato a ogni IMEI.
- Output atteso per il business: CSV di disaggregazione, grafici temporali, report energetico e benchmark comparativo tra approcci.

Abitazioni idonee

H1 = 86684007269866, H2 = 86684007269887, H3 = 86684007269889, H4 = 86853106211162, H5 = 86853106211173, H6 = 86853106211179.

Dati e pipeline end-to-end

Input

- JSON IoT per IMEI con segnale `w_medio` a granularita' minuto.
- Inventario survey legacy `device_usage_by_imei`.
- Inventario survey V2 `device_usage_by_imei_v2` con bounds, finestre orarie e stagionalita'.

Pipeline

- 1 Preprocessing e ricampionamento a 1 minuto.
- 2 Costruzione dei `DeviceProfile`.
- 3 Esecuzione dell'approccio scelto tramite interfaccia comune `run(signal, devices)`.
- 4 Salvataggio di `disaggregation.csv`, plot temporali e report energetico.
- 5 Benchmark proxy basato su errore di ricostruzione, energia e consistenza temporale.

$$\hat{w}(t) \approx \sum p_i(t), \quad \text{MAE} = \frac{1}{T} \sum |w_{\text{total}}(t) - \hat{w}(t)|$$

- `DeviceProfile` e' il contratto condiviso da tutti i modelli. Contiene potenze minime, tipiche e massime, durata minima e tipica, duty cycle, frequenza, prior, flag always-on e metadati opzionali per vincoli survey-aware.
- `DEVICE_KNOWLEDGE_BASE` incapsula la knowledge base ingegneristica di 15 categorie: frigoriferi, carichi di cottura, microonde, climatizzazione, TV, computer, auto elettrica e altri.
- `get_device_profiles()` converte l'inventario legacy in profili operativi. La presenza del device imposta `prior_weight = 1.0`; l'assenza lo degrada a 0.05 invece di escluderlo del tutto.
- Questo file e' il punto centrale di allineamento tra survey, priors, benchmark e approcci: cambia una sola volta e si aggiorna l'intera pipeline NILM.

Deep dive: device_usage_by_imei_v2

- La directory V2 deriva da `build_questionnaire_device_usage_v2.py`, che normalizza un export questionario grezzo in JSON strutturati per IMEI.
- Ogni device salva bounds numerici, non solo un valore medio: `usage_frequency_per_week_min/max`, `duration_minutes_min/max`, finestre di start, ore giornaliere, mesi attivi e `warning` di qualità'.
- `get_device_profiles_v2()` riduce questi bounds a valori rappresentativi per l'inferenza, ma mantiene anche i limiti massimi utili nei modelli survey-aware.
- Questa struttura abilita euristiche piu' forti: commitment window guidata dal survey, cap di durata, numero massimo di blocchi, finestre orarie e stagionalita'.

Esempio pratico

Per Lavatrice si possono avere frequenza settimanale 1–2, durata 0–60 minuti e finestra 06:00–10:00; per Climatizzatore si possono avere 2–4 ore/giorno e mesi attivi 6–9.

Approccio: Event-based

- Modello piu' semplice: rileva eventi ON/OFF tramite `delta_w = signal.diff()` e soglia fissa, poi associa ogni salto positivo al device con potenza tipica piu' vicina.
- Ogni evento ON viene accoppiato con il primo OFF compatibile entro `dur_typical x 3`; in mancanza di OFF usa una durata di default.
- Punti di forza: spiegabile, veloce, utile come baseline interpretabile.
- Limiti: fragile con carichi sovrapposti o salti di potenza non puliti.
- Benchmark 6 case: MAE medio 151.44 W.

Approccio: Event-based con prior

- Mantiene la logica event-based ma sostituisce la sola prossimità in potenza con uno score bayesiano: likelihood sul salto osservato per prior di presenza e frequenza d'uso dichiarata.
- L'inventario survey non elimina i device assenti, ma li penalizza in modo forte tramite `prior_weight`.
- Punti di forza: migliore allineamento con il contesto reale rispetto al puro matching per potenza.
- Limiti: rimane dipendente dalla qualità del rilevamento eventi e non modella bene i carichi simultanei lunghi.
- Benchmark 6 case: MAE medio 150.40 W, miglioramento marginale rispetto all'event-based puro.

Approccio: HMM per singolo device

- Per ogni device presente viene fittato un GaussianHMM a 2 stati ON/OFF sul residuo corrente, con inizializzazione delle medie da knowledge base.
- La sequenza di device viene stimata in cascata: dopo ogni device, il contributo stimato viene sottratto dal residuo globale.
- Punti di forza: struttura probabilistica chiara e uso di una libreria standard.
- Limiti: decomposizione sequenziale, forte sensibilit  agli errori iniziali e risultati deboli in presenza di simultaneit .
- Benchmark 6 case: MAE medio 2110.03 W, il peggiore tra gli approcci a copertura completa.

Approccio: FHMM semplificato

- Modella tutti i device simultaneamente con catene latenti binarie indipendenti e inferenza greedy tipo coordinate-ascent.
- Ogni stato $x_i(t)$ viene aggiornato minimizzando l'errore di ricostruzione sul residuo generato dagli altri device; a convergenza si applica smoothing temporale sui blocchi troppo brevi.
- Punti di forza: rappresenta combinazioni simultanee senza esplosione combinatoria completa.
- Limiti: potenza binaria fissa e nessuna modellazione esplicita di carichi always-on.
- Benchmark 6 case: MAE medio 71.35 W, seconda miglior media tra i modelli con copertura completa.

Approccio: fhmm_1 peak baseline

- Estende FHMM introducendo una baseline costante per i carichi always-on e lavorando solo sul residuo positivo dei device event-driven.
- Usa una commitment window: una volta acceso, il device rimane ON per almeno `dur_typical_min`; i device bursty come il microonde mantengono potenza fissa.
- Punti di forza: piu' realistico del FHMM base per frigoriferi e cicli continui.
- Limiti: la baseline a potenza di picco puo' sovrastimare gli always-on in diversi contesti abitativi.
- Benchmark 6 case: MAE medio 80.92 W.

Approccio: fhmm_1_dc duty-average baseline

- Mantiene la struttura di fhmm_1 ma usa per gli always-on una baseline media pari a $p_{\text{typical}} * \text{duty_cycle}$, anzichè la potenza di picco.
- Questo riduce la sovra-assegnazione sistematica dei carichi frigoriferi e libera residuo utile per i carichi intermittenti.
- Punti di forza: ottimo compromesso tra semplicità, stabilità e accuratezza.
- Limiti: resta un modello euristico, con potenza assegnata principalmente guidata dal residuo.
- Benchmark 6 case: MAE medio 27.64 W, miglior risultato globale tra gli approcci con copertura completa.

Approccio: fhmm_1_survey

- Variante survey-aware di fhmm_1: la soglia di attivazione viene modulata in base a finestre di start, mesi attivi, durata massima, frequenza massima e ore giornaliere del questionario V2.
- Introduce euristiche operative molto vicine a un ragionamento di dominio: ad esempio limita i blocchi giornalieri o favorisce l'accensione dentro la finestra oraria dichiarata.
- Punti di forza: piu' adatto a dispositivi con pattern temporali forti e questionario ricco.
- Limiti: benchmark ancora parziale, dipendente dalla qualita' del survey V2 disponibile per la casa.
- Benchmark attuale: MAE medio 49.50 W su 2 abitazioni.

Approccio: Template matching

- Costruisce per ogni device un template rettangolare di potenza tipica e durata tipica, poi calcola cross-correlazione normalizzata con il segnale aggregato.
- I picchi sopra soglia vengono assegnati in modo greedy senza overlap, con priorit  ai device piu' potenti.
- Punti di forza: semplice da interpretare e rapido da eseguire.
- Limiti: i consumi reali raramente seguono template rettangolari puliti; la metodologia degrada molto con rumore e device sovrapposti.
- Benchmark 6 case: MAE medio 1149.56 W.

- Formula il NILM come problema di Mixed-Integer Quadratic Programming: minimizza l'errore quadratico tra segnale aggregato e somma dei contributi binari dei device su chunk settimanali.
- L'architettura supporta variabili di stato, attivazioni, spegnimenti, vincoli di durata e penalita' sulle accensioni, con forte controllabilita' modellistica.
- Punti di forza: massima espressivita' tra gli approcci attuali e ottimo fit con vincoli di business espliciti.
- Limiti: costo computazionale elevato e benchmark ancora molto parziale.
- Benchmark attuale: MAE medio 147.01 W su 1 sola abitazione.

Approccio: Gurobi daywise

- Variante piu' pragmatica: assegna una baseline sempre accesa ai frigoriferi, la sottrae dal segnale e risolve il residuo giorno per giorno con un solver binario Gurobi piu' piccolo.
- In `gurobi_methods.py` sono state aggiunte anche le estensioni `constrained_v1` e `constrained_v2`, che introducono variabili di transizione, durata massima consecutiva e finestre orarie.
- Punti di forza: migliore trattabilita', architettura modulare e forte potenziale di controllo dei falsi positivi.
- Limiti: sensibilita' elevata alle abitazioni piu' difficili; H6 rimane un caso critico con MAE 212.60 W.
- Benchmark 6 case: MAE medio 77.02 W.

Approccio: Gurobi multilevel 3 e 5 stati

- Il nuovo modulo `gurobi_multiple.py` generalizza il modello binario a piu' livelli di potenza: ogni device puo' essere OFF o scegliere uno tra 3 o 5 livelli discreti.
- I livelli sono ottenuti per interpolazione lineare tra `p_min`, `p_typical` e `p_max`; il livello centrale coincide con la potenza tipica, gli altri si avvicinano ai bound senza coincidere con essi.
- Le varianti disponibili sono: `unconstrained`, `v1` con variabili `u/dw` e durata massima, e `v2` con finestre orarie per microonde e lavatrice.
- Punti di forza: rappresenta meglio device con potenza non binaria e apre la strada a modelli piu' realistici per forno, climatizzazione e lavatrice.
- Stato: implementato e integrato nel runner, ma benchmark sistematico ancora da completare.

Focus Gurobi: evoluzione della famiglia di modelli

Versione	Idea chiave	Copertura	Stato
Weekly MIQP	Solve settimanale binario con alta espressività modellistica	1 casa	Benchmark iniziale
Daywise binary	Baseline always-on + solve giornaliero sul residuo	6 case	Variante piu' matura
v1	Variabili u/dw e durata massima consecutiva	0 case complete	Implementata, test da fare
v2	V1 + finestre orarie per device selezionati	0 case complete	Implementata, test da fare
Multilevel 3/5	Livelli di potenza multipli con versioni unconstrained/v1/v2	0 case complete	Pronta per benchmark

Messaggio chiave


La famiglia Gurobi non e' ancora la migliore in media rispetto a `fhmm_1_dc`, ma e' la piu' promettente come piattaforma industriale per introdurre vincoli espliciti, multi-stato e regole di dominio controllabili.

Metodologia benchmark

- Non esistono labels temporali di ground truth; per questo il benchmark e' proxy e misura la qualita' di ricostruzione del segnale aggregato.
- La metrica principale usata in questa presentazione e' il **MAE di ricostruzione**, calcolato come media del valore assoluto del residuo salvato in ogni `disaggregation.csv`.
- Sono presenti anche altre metriche nel modulo `benchmark.py`: RMSE, errore energetico percentuale, residuo medio, numero di device trovati e consistenza temporale.
- Per evitare confronti distorti, il ranking principale considera solo gli approcci con copertura completa su tutte le 6 abitazioni idonee.

$$\text{MAE}_{\text{recon}} = \frac{1}{T} \sum_{t=1}^T \left| w_{\text{total}}(t) - \sum_i \hat{w}_i(t) \right|$$

Confronto risultati: MAE medio su 6 case



Lettura del grafico: fhmm_1_dc e' il best performer medio; gurobi_daywise e' nel gruppo competitivo ma non ancora al vertice; HMM e template sono nettamente fuori scala.

Confronto risultati: MAE per abitazione

Approach	H1	H2	H3	H4	H5	H6
FHMM-1 duty avg	33.63	6.56	69.62	0.63	14.40	40.97
FHMM	63.97	63.01	115.26	80.40	55.84	49.61
Gurobi daywise	43.78	46.60	38.85	50.65	69.62	212.60
FHMM-1 peak	59.21	24.00	110.06	24.02	50.23	217.99
Event + prior	107.70	222.77	178.09	165.44	133.48	94.93
Event-based	109.35	218.94	187.46	163.29	134.95	94.63
Template	1483.00	1086.05	748.92	1712.53	781.27	1085.59
HMM	1454.29	1942.48	1409.07	2595.56	2505.15	2753.60

Mappatura: H1=86684007269866, H2=86684007269887, H3=86684007269889, H4=86853106211162, H5=86853106211173, H6=86853106211179.

Risultati parziali e stato sperimentale

Approcci con benchmark parziale

- fhmm_1_survey: MAE medio 49.50 W su 2 case. Segnale incoraggiante, ma copertura ancora troppo limitata per ranking finale.
- gurobi: MAE 147.01 W su 1 casa. Utile come prova di formulazione, non ancora sufficiente come baseline industriale.

Approcci implementati, benchmark pending

- constrained_v1: transizioni u/dw + durata massima consecutiva.
- constrained_v2: v1 + finestre orarie per microonde e lavatrice.
- gurobi_multiple: livelli di potenza 3 e 5 con versioni unconstrained, v1 e v2.

Interpretazione manageriale

Le estensioni piu' recenti non sono ancora da considerare perdenti o vincenti: il loro valore attuale e' architetturale, perche' aprono un percorso chiaro verso modelli controllabili e piu' fedeli al comportamento reale dei device.

Raccomandazioni operative

- Produzione a breve termine: usare `fhmm_1_dc` come baseline migliore per accuratezza media e robustezza sulle 6 case benchmarkate.
- Ricerca applicata: mantenere `gurobi_daywise` come ramo di sviluppo principale quando il requisito e' inserire vincoli espliciti e controlli per device specifici.
- Survey-aware roadmap: ampliare la copertura di `device_usage_by_imei_v2` per portare `fhmm_1_survey` e `gurobi_v2` su tutte le abitazioni.
- Benchmark next step: lanciare in batch le 6 varianti multi-livello `gurobi_multiple_*` su tutte le 6 case e confrontarle con `fhmm_1_dc` e `gurobi_daywise`.
- KPI di decisione: oltre al MAE, monitorare energia residua, falsi positivi su microonde/lavatrice e stabilita' temporale dei blocchi ON.

Conclusioni

- La codebase oggi copre un ventaglio ampio di approcci, dalle euristiche leggere ai modelli con ottimizzazione matematica esplicita.
- Il cuore informativo del progetto e' la combinazione tra knowledge base ingegneristica in `devices.py` e arricchimento survey in `device_usage_by_imei_v2`.
- Il benchmark attuale indica una gerarchia chiara: `fhmm_1_dc` come best performer medio, FHMM e `gurobi_daywise` come seconde linee competitive, HMM e template non raccomandati.
- La famiglia Gurobi rimane il percorso piu' promettente per introdurre regole operative, multi-stato e explainability di tipo industriale.

Messaggio finale: la piattaforma e' gia' adatta a una fase aziendale di valutazione comparativa e prioritizzazione di una roadmap product-oriented.